Projeto Primeiro Bimestre

Nomes: Giovanna Micher Santana e Lucas Gargalhone, RA: 10401330 e 10401284

1. Definição do Problema

Clarifique o problema ou a questão que o trabalho busca resolver.

A indústria de hotelaria nos EUA emprega milhões de pessoas no país. Essa indústria foi fortemente afetada por conta da pandemia do COVID-19, durante o início da pandemia a taxa de comércio ativos foi a mais baixa dos últimos três anos, registrando por volta de 38% (Mathews, 2021).

Em 2022, tivemos um cenário ainda de recuperação, porém muito mais otimista, abaixo constam alguns dados sobre o ano de 2022 da indústria de hoteleira americana:

Impactos econômicos da indústria hoteleira nos EUA em 2022:

- Quase **62.500 hotéis**
- **5,6 milhões** de quartos disponíveis para hóspedes
- Quase **1,3 bilhão** de noites de quartos vendidas
- **8,3 milhões** de empregos gerados (diretos e indiretos), representando **1 em cada 25 empregos** nos EUA
- **$1,5 trilhão** em vendas apoiadas por empresas nos EUA
- **$759,9 bilhões** contribuídos ao PIB dos EUA

Fatos adicionais de 2022:

- Vendas de hotéis: **$323,7 bilhões** (incluindo receitas e alguns impostos)
- Hotéis apoiam **$463,2 bilhões** em salários, remunerações e compensações, incluindo **$104,7 bilhões** apenas nas operações de hotéis
- Hotéis contribuem com **$211,2 bilhões** em impostos federais, estaduais e locais, o que equivale a **$1.656 por domicílio** nos EUA anualmente
- Hóspedes gastaram **$691,2 bilhões** em hotéis, empresas locais e transporte

- **4,7 milhões** de empregos gerados diretamente
- Hotéis compraram **$119,2 bilhões** em insumos de outras empresas americanas(American Hotel and Lodging Association)

Esse trabalho busca entender e modelar dados do segmento de hotelaria dos Estados Unidos, para determinar estratégias de precificação assertivas e marketing direcionado à determinadas épocas do ano além de entender melhor o comportamento de outras métricas desse segmento como a taxa diária média (ADR) e sua relação com outras variáveis.

2. **Por que esse problema é importante e o que motiva a sua solução.**

O problema é importante porque o setor de turismo dos Estados Unidos é altamente competitivo e sazonal, sendo uma das indústrias de grande impacto para a economia do país. No ano de 2022, houve mais de 8 milhões de empregos gerados por esse setor, $1,463.3 bilhões de vendas geradas pela indústria, $759.9 bilhões de contribuição direta e indireta ao Produto Interno Bruto dos EUA, além de todo o impacto indireto gerado.

Empresas que conseguem entender os padrões de comportamento dos consumidores e ajustar suas estratégias de precificação e marketing podem melhorar significativamente suas margens de lucro, atraindo mais turistas em períodos estratégicos.

A motivação para o projeto é que os estabelecimentos possam se organizar para atender à alta demanda proveniente das épocas de maior procura, e racionalizar seus custos operacionais em épocas de menor demanda.

3. **Perguntas da Pesquisa**

1. Como os dados de turismo podem ser utilizados para identificar as épocas de maior e menor demanda?

A identificação de épocas de maior e menor demanda pode ser feita considerando o volume de check-in’s em relação ao tempo. Para caso de estudo,

o número de check-in’s pode ser correlacionado com outras variáveis além da época do ano, como a quantidade de adultos/crianças, a agência, o local do hotel.

2. **Como o número de solicitações especiais feitas pelos clientes influencia a satisfação geral e a probabilidade de retorno em futuras estadias?**

A correlação entre o número de solicitações especiais feitas pelos clientes e o cancelamento da reserva (representado pela variável `is_canceled`) é **0.234877**, o que indica uma **correlação positiva moderada**. Isso sugere que, quanto maior o número de solicitações especiais feitas por um cliente, **maior é a chance de cancelamento** da reserva, embora a correlação não seja forte.

Além disso, a correlação entre a variável `is_repeated_guest` e o cancelamento é **0.083745**, o que mostra que clientes com histórico de estadias anteriores têm uma ligeira tendência a não cancelar suas reservas. Isso implica que **clientes que fazem solicitações especiais não necessariamente retornam com mais frequência**, já que o número de solicitações está mais correlacionado ao cancelamento do que ao retorno.

3. **Pessoas com pedidos especiais têm mais chance de voltar ou cancelar?**

A **correlação entre solicitações especiais e cancelamentos é positiva (0.234877)**, indicando que clientes com pedidos especiais têm uma chance maior de cancelar suas reservas. A correlação com a variável `is_repeated_guest` (indicativa de retorno) é baixa (0.083745), sugerindo que essas pessoas **não têm uma chance significativamente maior de retornar**, e a correlação positiva com o cancelamento indica uma **maior tendência de cancelamento**.

4. **Quais estratégias de precificação são mais eficazes para atrair turistas durante as épocas de baixa demanda?**

Algumas estratégias que fazem sentido para ajudar atrair turistas durante épocas de baixa demanda seriam descontos sazonais, essa estratégia se caracteriza na redução dos preços durante esses períodos. Outra estratégia seria criar pacotes promocionais, combinar estadias com serviços adicionais, como pacotes com atividades turísticas. E por último uma estratégia mais agressiva de ofertas de

última hora, esse tipo de oferta faz muito sentido quando olhamos a distribuição do lead time.

5. **De que forma campanhas de marketing direcionado podem impactar o comportamento dos turistas em épocas específicas do ano?**

Campanhas de marketing direcionado podem ser projetadas para impactar o comportamento dos turistas com base em temporada de férias ou analisando a preferência dos turistas. Ofertas que expiram em um curto prazo podem criar um senso de urgência, aumentando a demanda em épocas de baixa ocupação.

6. **Como a segmentação de dados pode auxiliar no desenvolvimento de campanhas personalizadas para diferentes perfis de turistas?**

A segmentação de dados, como a identificação de turistas que retornam, a coluna `is_repeated_guest`, famílias com crianças ou adultos, ou aqueles que fazem solicitações especiais, permite criar campanhas específicas que abordam as necessidades de cada grupo.

Para famílias grandes com crianças podem ser oferecidas campanhas com serviços de recreação/ atividades para crianças. Para turistas poderiam ser oferecidos pacotes com rotas de viagem para casal/pontos turísticos. Também seria interessante analisar os 'is_repeated_guest' altos e criar programa de fidelidades para esses casos.

4. Revisão Bibliográfica

Descreva as ferramentas de software (como Python ou outra que usou) e bibliotecas (como pandas, scikit-learn ou outras) que serão usadas.

As técnologias utilizadas para o desenvolvimento desse estudo se concentram em técnicas de machine learning, utilizando a linguagem de programação Python. Para utilizar os algoritmos que serão responsáveis por treinar o modelo utilizaremos a biblioteca scikit-learn.

5. Coleta de Dados

Identifique e descreva as fontes dos dados utilizados (datasets públicos, dados coletados por você, etc.).

Utilizamos uma fonte de dados pública da plataforma Kaggle.

Discuta a qualidade dos dados, incluindo problemas de missing data, outliers e a necessidade de pré-processamento.

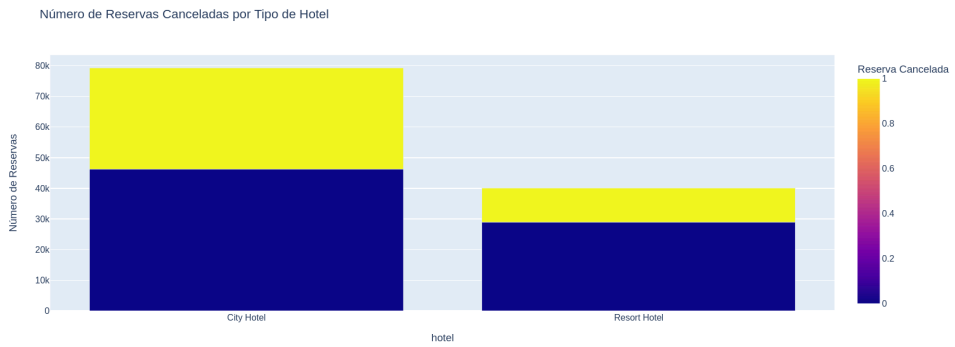
Segundo Antonio (2018), criador de datasets de agendamento de hotéis, sobre os campos com valores faltantes como em Agent ou company, as linhas apresentadas como NULL não devem ser consideradas valores faltantes e sim “não aplicável”, por exemplo, se Agent é NULL, isso significa que o booking não foi feito através de uma agência de viagens.

Coluna	Quantidade valores faltantes
children	4
country	488
agent	16340
company	112593

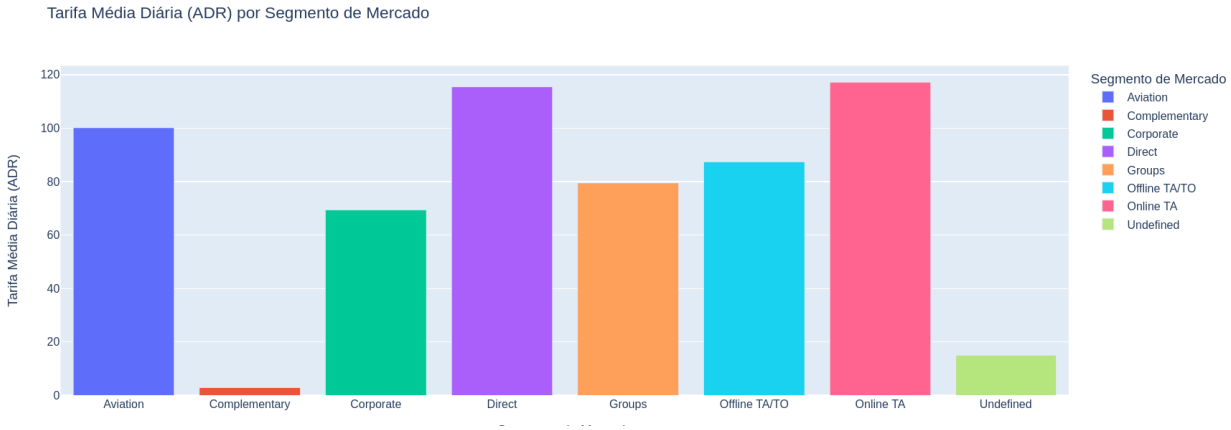
Para limpeza da base aplicamos transformações nas colunas para manter as mesmas escalas entre os dados numéricos, e transformações como one-hot encoding para dados categóricos.

6. Análise Exploratória dos Dados (EDA)

Sobre o numero de reservas canceladas, notamos uma taxa maior de cancelamento em hotéis na cidade comparado a resorts, sendo que cerca de 29k reservas canceladas por pessoas que nunca cancelaram previamente

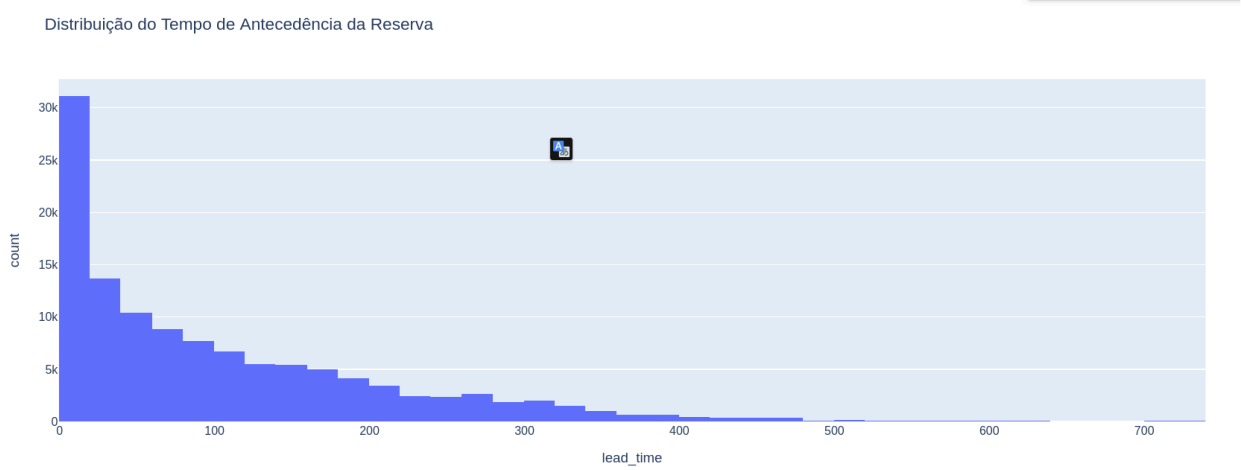


Outra métrica interessante foram os seguimentos que geram o maior ADR (Tarifa Média diária), essa métrica é a receita total dos quartos dividido pelo numero de quartos ocupados. Esse numero ajuda hotéis a comparar sua performance com outros hotéis no mesmo mercado.



Para surpresa, o segmento corporativo esta responsável pelos menores ADR, e os maiores seriam vendas diretas e TA (tour agencies)

Um comportamento já esperado era sobre a distribuição do tempo de antecedencia da reserva



Também qual são países de onde os hóspedes estão vindo, sendo o top3: Portugal, Reino Unido e França

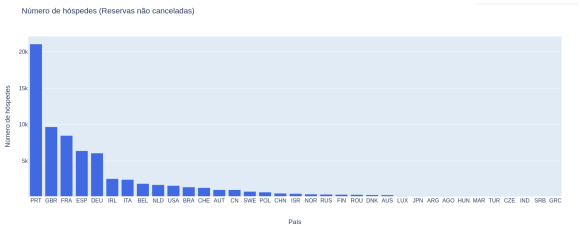
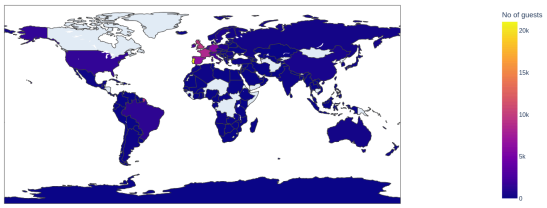


Gráfico de barra



Mapa

Estatísticas Descritivas

```
Estatísticas ADR:
count       119390.0
mean        101.831122
std          50.535790
min          -6.380000
25%          69.290000
50%          94.575000
75%         126.000000
max        5400.000000

Estatísticas Cancelamento:
0    0.629584 #nao cancelado
1    0.370416 #cancelado
```

Tambem usamos uma matriz de correlação para identificar as variaveis com maior relação a probabilidade de cancelamento, sendo

	is_canceled	adr
is_canceled	1.000000	0.047557
lead_time	0.293123	-0.063077
arrival_date_year	0.016660	0.197580
arrival_date_week_number	0.008148	0.075791
arrival_date_day_of_month	-0.006130	0.030245
stays_in_weekend_nights	-0.001791	0.049342
stays_in_week_nights	0.024765	0.065237
adults	0.060017	0.230641
children	0.005048	0.324854
babies	-0.032491	0.029186
is_repeated_guest	-0.084793	-0.134314
previous_cancellations	0.110133	-0.065646
previous_bookings_not_canceled	-0.057358	-0.072144
booking_changes	-0.144381	0.019618
agent	-0.083114	-0.024695
company	-0.020642	0.086376
days_in_waiting_list	0.054186	-0.040756
adr	0.047557	1.000000
required_car_parking_spaces	-0.195498	0.056628
total_of_special_requests	-0.234658	0.172185

7. **Modelagem**

- **Escolha do Modelo:** MLP (Multi-layer perceptron), com 100 neurônios na primeira camada oculta e 50 neurônios na segunda camada oculta. O modelo

foi treinado com um número máximo de 400 épocas, tambem usamos uma semente para inicializar os pesos do treinamento.

- **Treinamento e Validação:** O modelo foi treinado utilizando o metodo k-fold estratificado, mantendo as proporções dos labels entre as classes.
- **Avaliação do Desempenho:**

```
Métricas de Desempenho da Rede MLP com K-Fold:
Acurácia: 0.9984
Precisão: 0.9988
Recall: 0.9970
F1-Score: 0.9979
```

8. Resultados

Interpretação: Com o tratamento adequado, conseguimos atingir resultados satisfatórios, 99,8% de acurácia, porém a indústria de hotelaria ainda enfrenta forte influência de outras variáveis provindas de outros setores que não estão presentes no dataset. Esse estudo feito em ambiente controlado mostra um cenário otimista quanto a modelagem para previsão de cancelamento de reservas, com um enriquecimento maior de variáveis esses modelos estariam mais preparados para cenários do mundo real.

Limitações: Enfrentamos algumas dificuldades relacionadas quanto a base de dados, no contexto de hotelaria, é comum que os clientes mudem os atributos das reservas deles, como o número de pessoas, duração da estadia, ou preferências do tipo de quarto, seja no horário do check-in ou durante a estadia (Antonio, 2018).

9. Conclusão

Resumo: O estudo demonstra que, com o tratamento adequado dos dados e a escolha de um modelo robusto (como redes neurais), é possível obter resultados promissores na previsão de cancelamento de reservas. A alta acurácia (99,8%) sugere que o modelo tem potencial para ser utilizado como uma ferramenta de

auxílio à gestão de reservas, ajudando a prever cancelamentos e a otimizar a operação de hotéis.

Implicações Práticas: O modelo pode ajudar a otimizar o gerenciamento de recursos, como a alocação de quartos e a gestão de pessoas, ao prever a demanda com base na probabilidade de cancelamento. Para um caso de uso real, seria necessário adaptar as condições sistemas do hotel, adicionando mais variáveis ao modelo, podendo assim oferecer contexto de situações reais ao modelo.

Sugestões para Trabalhos Futuros: Um trabalho futuro poderia ser o enriquecimento desses dados, sejam por algum sistema que centralize essas informações ou alguma canal para consumo desses dados, informações interessantes seriam dados sobre a região do hotel/hospede, informações econômicas, eventos que irão acontecer na região.

10. **Referências**

MATTHEWS Real Estate Investment Services. *H2 2023 U.S. Hotel Industry Outlook*. Disponível em: https://www.matthews.com/h2-2023-u-s-hotel-industry-outlook/. Acesso em: 29 set. 2024.

AMERICAN HOTEL & LODGING ASSOCIATION. *Oxford Economics: Economic Impact of the U.S. Hotel Industry 2019*. Disponível em: https://www.ahla.com/sites/default/files/oxford2019.pdf. Acesso em: 29 set. 2024.

ANTONIO, N.; de Almeida, A.; NUNES, L. Hotel booking demand datasets. Data in Brief, v. 22, p. 41–49, 2019. ISSN 2352-3409

11. **Apêndices (se necessário)**

- **Código Fonte:** Inclua qualquer código que foi escrito para o trabalho.

mack_ciencia_dados.py

- **Documentação Adicional:** Qualquer outro material relevante, como dados brutos, tabelas complementares, etc.

hotel-booking-demand.zip